HermesQA — Báo cáo tình trạng thực nghiệm

Ngày 06/10/2026, cập nhật 12:30 · Người nhận: Phí Thành Dương · Soạn bởi Claude (phiên hermesqa-33), phối hợp với phiên hermesqa-f5 đang chạy đo

> **Tóm tắt một đoạn.** Lần đo bạn đang chạy (`eval/out-v3`, cấu hình `both`) đã **dừng và thất bại toàn bộ 35/35 case** lúc 11:38: case đầu đụng hạn mức Gemini free tier (500 request/ngày cho `gemini-3.1-flash-lite`, reset lúc 07:00 ngày 07/10), 34 case còn lại lỗi vì Docker daemon đang tắt lúc đó (nay đã bật lại). Ngoài ra, lần chạy `llm` hôm 05/10 lộ ra một lỗi trong bước fact-check mới (loại nhầm 4 finding đúng do "lý luận vòng"), đã được sửa trong mã nguồn nhưng chưa commit và cần chạy lại để xác nhận. Vì vậy **chưa có số liệu chốt cho pipeline mới** trên hai bộ lỗi tiêm; kế hoạch chạy nốt vào sáng 07/10 đã được tính vừa hạn mức một ngày. **Pilot trên 15 PR thật (AACR-Bench) đã chốt trong ngày và là kết quả âm:** F1 1–3 %, recall 1,5–2,9 % trên 68 vấn đề chuẩn (mục 4b). Điều này cho thấy bộ eval lỗi tiêm đánh giá quá cao và cần được nói rõ trong báo cáo.

1. Tình trạng từng lượt đo (đến 11:40 ngày 06/10)

Lượt chạy	Thư mục	Đã xong	Tình trạng	Ghi chú
Python `llm` (fact-check)	`eval/out-v3/llm`	35/35	phải chạy lại	Chạy 05/10 *trước* khi sửa lỗi fact-check (mục 3)
Python `llm_noverify`	`eval/out-v3/llm_noverify`	34/35	giữ được	Không dùng fact-check; 1 case (`string-concat-loop`) lỗi JSON hỏng sẽ tự chạy lại
Python `llm_legacyverify`	`eval/out-v3/llm_legacyverify`	18/35	chạy nốt	16 case lỗi hạn mức, 1 timeout. Recall 55,6 % hiện thấy là do lỗi chạy, không phải do kiểm chứng kiểu cũ
Python `both`	`eval/out-v3/both`	0/35	thất bại	Case 1 hết hạn mức sau 168 s; 34 case còn lại lỗi Docker trong ~4 s mỗi case
Đa ngôn ngữ `llm`	`eval/out-multi-v3/llm`	18/18	phải chạy lại	Trước khi sửa fact-check
Đa ngôn ngữ `both`	`eval/out-multi-v3/both`	7/18	chạy nốt	9 case lỗi Docker, 2 timeout
Python `static` (v3)	—	0/35	chưa chạy	Không cần LLM; static không đổi so với v2 nhưng cần cột đối chứng trong bảng v3
Pilot PR thật (AACR-Bench)	`eval/aacr/out`	15/15	đã chốt	15 PR Python, 68 vấn đề chuẩn, model `gemini-3.5-flash-lite`, giám khảo 3 phiếu; kết quả ở mục 4b

2. Nguyên nhân dừng và cách xử lý

2.1 Hạn mức Gemini free tier

Giới hạn là **500 request/ngày/model**. Đếm từ metadata của lần chạy v3, một cấu hình có bước kiểm chứng tốn khoảng 118 request cho 35 case Python (59 lượt review + 59 lượt kiểm chứng, vì mỗi vai mỗi lô là một lượt), `llm_noverify` tốn 58, bộ đa ngôn ngữ `llm` tốn 68. Bốn cấu hình Python cộng bộ đa ngôn ngữ vượt hạn mức một ngày, nên lượt `both` sáng nay chết ngay ở case đầu.

Xử lý: hai phiên đã thống nhất kế hoạch chạy nốt sau 07:00 ngày 07/10 (mục 5), chỉ chạy lại những gì thật sự cần (khoảng 420 request), giữ nguyên `llm_noverify` vì bản sửa fact-check không ảnh hưởng cấu hình này. Phiên hermesqa-f5 cũng vừa thêm cơ chế đợi theo phút khi gặp 429 và nới parser JSON (`strict=False`) để bớt case lỗi vặt.

2.2 Docker daemon tắt

Cấu hình `both` cần sandbox; lúc 11:38 daemon không chạy nên 34 case lỗi liên tiếp trong vài giây. Hiện Docker đã bật (phiên bản 29.8.0) và toàn bộ test tích hợp đã pass. Trước khi chạy lại ngày mai cần kiểm tra Docker Desktop còn chạy, vì theo kinh nghiệm các phiên trước daemon thường tắt khi mở máy lại.

3. Lỗi mới phát hiện trong bước fact-check (E8)

Bước fact-check (thay cho self-verify) chỉ cho phép LLM loại một nhận xét khi nêu được bằng chứng là một dòng có thật trong diff. Lần chạy `llm` hôm 05/10 cho thấy model loại 5 nhận xét, trong đó **4 là nhận xét đúng**:

Case	Nhận xét bị loại	"Bằng chứng" model đưa	Vấn đề
`eq-none` (×2)	Dùng `==` thay vì `is` khi so với None	`if user == None:`	Bằng chứng chính là dòng bị báo — lý luận vòng
`unused-import` (×2)	Import không dùng	`import json`	Như trên
`docker-sudo`	Thiếu `--no-cache-dir` khi pip install	`RUN sudo pip install -r requirements.txt`	Loại đúng (nhận xét ngoài ground truth)

Phần mềm trước đây chỉ kiểm "dòng bằng chứng có thật trong diff", chưa kiểm "dòng đó có phải chính dòng bị báo không". **Đã sửa** (phiên hermesqa-f5, chưa commit): căn cứ B bị bác nếu bằng chứng trùng `existing_code` của nhận xét; thêm test hồi quy với ba cách chép khác nhau; nhận xét bị loại nay được lưu nguyên vẹn vào metadata để có thể chấm lại offline. Việc sửa này là lý do cấu hình `llm` và `both` phải chạy lại từ đầu.

4. Số sơ bộ — chỉ để chẩn đoán, KHÔNG dùng để kết luận

> Các số dưới đây đo *trước* khi sửa lỗi E8 và có lượt chưa chạy xong. Chúng chỉ cho thấy xu hướng; số chốt sẽ nằm ở `eval/out-v3/results.md` sau lượt chạy ngày 07/10. Cột "v2" là số chốt của pipeline cũ (báo cáo tiến độ mục 7.2–7.3).

Bộ / cấu hình	Case OK	TP	FP	FN	F1 v3 (±3 dòng)	F1 v2	s/PR	token/PR
Python `llm` (fact-check, trước E8)	35/35	32	6	4	86,5 %	70,1 %	24,2	6.239
Python `llm_noverify`	34/35	34	5	2	90,7 %	69,4 %	11,8	4.410
Python `llm_legacyverify`	18/35	20	5	16	(65,6 %, không đại diện)	—	23,5	8.160
Python `both`	0/35	chưa có						
Đa ngôn ngữ `llm` (trước E8)	18/18	18	5	0	87,8 %	73,5 %	23,9	6.979
Đa ngôn ngữ `both`	7/18	chưa đủ để chấm						

Điều đáng chú ý trong số sơ bộ:

- **FP giảm mạnh** với pipeline mới: `llm` từ 27 xuống 6 trên bộ Python, từ 13 xuống 5 trên bộ đa ngôn ngữ (checklist "Không báo" + chia file theo vai). Cần kiểm tra trên PR thật (pilot AACR) để loại trừ khả năng overfit vào bộ eval tự tạo.
- **Fact-check hiện đang làm giảm điểm** (86,5 so với 90,7 khi tắt) vì 4 nhận xét đúng bị loại nhầm — đúng lỗi E8. Sau khi sửa, kỳ vọng `llm` lấy lại 4 TP này; cần số thật để xác nhận.
- **Ghim bằng code hoạt động:** 65/65 nhận xét trên bộ Python được ghim bằng `existing_code` (không phải bằng số dòng LLM đưa). Chấm ở tolerance 0 (phiên kia báo sơ bộ): 83,8 % so với 86,5 % ở ±3 dòng.
- Hai lỗi vẫn bị bỏ sót như các lần trước: `secret-aws` dòng 7 (artifact của cách chấm) và `new-func-no-test`.

4b. Pilot trên PR thật (AACR-Bench) — đã chốt, kết quả âm

15 PR Python ≤ 210 dòng từ ComfyUI, browser-use, ragflow, vllm, langflow; 68 vấn đề do kỹ sư xác nhận. Model review và giám khảo: `gemini-3.5-flash-lite`, 3 phiếu cho mỗi cặp. "Chặt" = cùng file, dòng trong ±3, giám khảo xác nhận cùng vấn đề.

Cấu hình	Finding	TP chặt	Precision	Recall	F1
`llm`	8	1	12,5 %	1,5 %	2,6 %
`both` (static chưa lọc theo hunk)	286	2	0,7 %	2,9 %	1,1 %
`both` + lọc static theo hunk (mới)	43	1	2,3 %	1,5 %	1,8 %

Theo mức ngữ cảnh cần có: 21 vấn đề diff-level (bắt 1), 29 file-level (0), 18 repo-level (0). Ba điều rút ra, phiên hermesqa-f5 đã commit kèm sửa lỗi (`2133adf`):

- **Bộ eval lỗi tiêm đánh giá quá cao.** Cùng pipeline: F1 86–90 trên lỗi tiêm, 1–3 trên PR thật. 69 % vấn đề thật cần ngữ cảnh file/repo mà pipeline không đưa cho model. Để so, agent tốt nhất trong bài báo AACR-Bench đạt recall khoảng 10 %.
- **LLM gần như im lặng trên code thật:** 8 nhận xét / 15 PR, 33 lượt gọi, không vai nào lỗi, fact-check không loại gì. Recall thấp là do model hạng nhẹ và checklist bảo thủ, không phải do lớp lọc.
- **Static trên repo thật chủ yếu báo code cũ:** 240/275 finding nằm ngoài hunk. Đã thêm bộ lọc static theo hunk vào cả CLI lẫn worker (34/34 test). Ngoài ra lượt pilot đầu đã review diff *đảo chiều* vì hiểu ngược hai trường commit của dataset; đã sửa và xác minh 68/68 vấn đề chuẩn nằm trong diff.

Đã ghi vào báo cáo tiến độ: bảng và phân tích ở mục 7.6, lỗi E9–E10 ở mục 5, hạn chế số 14 ở mục 9, hai hướng phát triển mới (ngữ cảnh file/repo; đo cùng 15 PR với model mạnh hơn), và một câu hỏi phản biện mới ở mục 10.

5. Việc đã làm hôm nay và việc tiếp theo

5.1 Đã làm (phiên này)

- Chẩn đoán lần đo thất bại; phối hợp và chia việc với phiên hermesqa-f5 (phiên đó giữ `app/`, `tests/`, `eval/` và việc chạy đo; phiên này giữ báo cáo).
- Soạn phần chữ cho 7 cải tiến đã triển khai vào `BAO_CAO_TIEN_DO.md`: mục 1.2, sơ đồ kiến trúc, 2.2 (4 module mới), 2.3 (7 bước mới), 4 (6 lớp chống bịa: ghim bằng code, fact-check có kiểm chứng cơ học, checklist "Không báo"), 5 nhóm E (E1–E7 + lỗi E8–E10), 6.2 (cấu hình và phép đo mới), 7.6 (tình trạng chạy lại, **bảng số Python/đa ngôn ngữ để trống**, pilot AACR đã điền và phân tích), 8, 9 (hạn chế mới: overfit checklist, giám khảo cùng model, hạn mức, kết quả âm trên PR thật), 10 (ba câu hỏi phản biện mới), 11 (thuật ngữ).
- Chạy `pytest` với Docker bật: **39/39 pass**.
- Tính ngân sách request cho lượt chạy ngày mai và gửi phiên kia; hai bên đã chốt kế hoạch.

5.2 Kế hoạch (đã thống nhất giữa hai phiên)

Khi nào	Việc	Request ước tính
06/10, xong	Pilot AACR 15 PR thật, `llm` và `both`, model `gemini-3.5-flash-lite`; kết quả `eval/aacr/out/results.md` (mục 4b)	đã dùng
Sau 07/10 (đề xuất)	Chạy `judge_fp.py` cho 42 finding còn lại của `both` trên AACR bằng model khác (`gemini-3.8-flash`) để tách "đúng ngoài ground truth" khỏi "sai"; đo lại 15 PR với backend Anthropic khi có key	~130
06/10 (tuỳ chọn)	Chạy `static` cho `eval/out-v3` — không tốn LLM, chỉ cần Docker (~1 giờ)	0
07/10 sau 07:00	Python: chạy lại `llm` + `both`, nốt 17 case `llm_legacyverify`; đa ngôn ngữ: chạy lại `llm`, nốt `both`. Giữ nguyên `llm_noverify`	~420 / 500
07/10, sau khi chạy xong	`score.py` (±3 và tolerance 0), `judge_fp.py` phân loại FP; điền bảng 7.6 và cập nhật mục 7.4/7.5, 10 của báo cáo tiến độ; xuất PDF báo cáo tiến độ; cập nhật `TONG_QUAN_DU_AN.html/.pdf` (vẫn đang dùng số cũ F1 53,0/54,8)	~50 (judge)

6. Lưu ý và rủi ro

- **Không đổi model giữa chừng** cho bộ Python và đa ngôn ngữ: đổi sang model còn hạn mức thì chạy nhanh hơn nhưng không so được với số cũ. Pilot AACR dùng model khác là chấp nhận được vì chỉ so `llm` với `both` trong cùng model.
- **Commit:** mã nguồn (sửa E8, lọc static theo hunk, diff AACR đúng chiều, test) đã vào commit `2133adf`, nên lượt chạy ngày mai sẽ đo đúng bản đã sửa. **Chưa commit:** phần chữ mới trong `BAO_CAO_TIEN_DO.md` và file PDF này; nên commit sau khi điền bảng số 7.6.
- **Trước khi chạy lại ngày mai:** kiểm tra Docker Desktop đang chạy; chạy từ `.venv` với `PYTHONIOENCODING=utf-8`; `run_eval.py` tự bỏ qua case đã OK nên có thể chạy nối tiếp nếu bị ngắt.
- **Điểm cần nói rõ khi bảo vệ** (đã ghi vào mục 9 của báo cáo tiến độ): checklist "Không báo" được viết sau khi nhìn thấy FP của bộ eval, nên FP giảm trên cùng bộ đó chưa chứng minh được tính tổng quát; pilot AACR là phép thử độc lập cho điểm này.

Tệp liên quan: `BAO_CAO_TIEN_DO.md` (báo cáo tiến độ, đã cập nhật phần chữ), `docs/DE_XUAT_CAI_TIEN_TU_OPEN_CODE_REVIEW.md` (7 đề xuất), `eval/out-v3/results.md` (số sơ bộ hiện tại), `eval/README.md` (cách chạy).